DeepSeekV3 改进

- 使用**偏置项动态调整**替代传统辅助损失来实现专家负载均衡
- 在训练过程中监控每个专家的负载，过载时降低偏置，欠载时增加偏置
- 在每个位置同时预测多个未来令牌
- 训练改进：
    - **首次**在超大规模模型（671B）上验证 FP8 训练的有效性
    - 实现**双向管道调度**，显著减少管道气泡
    - 定制通信内核，充分利用 IB 和 NVLink 带宽

Qwen3

```
58]: prompt = "Give me a short introduction to large language models."

     input_token_ids = tokenizer.encode(prompt)
     text = tokenizer.decode(input_token_ids)
     text # chatml

58]: '<|im_start|>user\nGive me a short introduction to large language models.<|im_end|>\n<|im_start|>assistant\n'

68]: multiturn_messages = [
         {"role": "user", "content": "你好，请介绍一下自己"},
         {"role": "assistant", "content": "你好！我是Qwen3助手，很高兴为你服务。"},
         {"role": "user", "content": "你能帮我写代码吗？"},
         {"role": "assistant", "content": "当然可以，请问你需要什么代码？"},
         {"role": "user", "content": "我的最开始的第一个提问是什么？"}
     ]

     # 编码多轮对话
     multiturn_ids = tokenizer.encode(multiturn_messages)
     text = tokenizer.decode(multiturn_ids)
     text # chatml

68]: '<|im_start|>user\n你好，请介绍一下自己<|im_end|>\n<|im_start|>assistant\n你好！我是Qwen3助手，很高兴为你服务。<|im_end|>\n<|im_start|>user\n你能帮我写代
     rt|>assistant\n当然可以，请问你需要什么代码？<|im_end|>\n<|im_start|>user\n我的最开始的第一个提问是什么？<|im_end|>\n<|im_start|>assistant\n'
```